

INFORME DE RESULTADOS

Replicación del artículo “Gait-Based Diplegia Classification Using LSTM Networks”

Ferrari et al. (2019), Journal of Healthcare Engineering

Elaborado por:

Pablo Cabrejos

Sara López Marín

Universidad EAFIT

Medellín, Colombia – 2026

1. Objetivo y Conjunto de Datos

Objetivo

- Replicar la clasificación automática de las 4 formas clínicas de diplejía a partir de datos crudos de marcha (marcadores ópticos VICON), siguiendo la metodología de Ferrari et al. (2019, Journal of Healthcare Engineering).
- Reconstruir el pipeline completo a partir de los datos crudos y comparar los resultados obtenidos con los reportados en el artículo original.

Conjunto de datos

- 178 pacientes, 1139 ensayos de marcha crudos (el artículo original usó 174 pacientes y ~1038 ensayos tras su propio procesamiento).
- 19 marcadores ópticos por frame, con captura a 100 fps (submuestreados a 50 fps).
- 4 formas clínicas desbalanceadas: la Forma IV es aproximadamente 8 veces más frecuente que la Forma I.

2. Metodología (Pipeline)

La reconstrucción del pipeline a partir del dato crudo se dividió en 5 grandes etapas y 8 pasos técnicos:

- 1. Adquisición de datos:** sistema optoelectrónico con 19 marcadores corporales, frecuencia de muestreo de 100 Hz.
- 2. Submuestreo:** reducción de la frecuencia de muestreo de 100 Hz a 50 Hz.
- 3. Detección de pasos y selección de ciclos completos:** identificación de foot-strikes y toe-offs; eliminación de pasos incompletos.
- 4. Normalización temporal:** estimación del período promedio T y selección de un número entero de ciclos.
- 5. Transformación espacial:** proyección de coordenadas 3D a los tres planos corporales (sagital, frontal, transversal).
- 6. Extracción de ángulos:** cálculo de 27 ángulos por plano, para un total de 81 ángulos por frame.
- 7. Representación para las redes neuronales:** ruta A (FFT, para el MLP) y ruta B (ventanas temporales, para el LSTM).
- 8. Split de los datos:** división entrenamiento/test 75:25 a nivel de paciente, sin mezclar trials del mismo paciente entre conjuntos.

3. Arquitecturas de los Modelos

Ruta A: FFT → MLP

- Se calcula la FFT de cada uno de los 81 ángulos y se conservan los primeros 20 coeficientes relevantes.
- Cada coeficiente se normaliza respecto a la amplitud fundamental.

- Vector de entrada final: $81 \text{ ángulos} \times 20 \text{ coeficientes} = 1620 \text{ valores}$.
- Arquitectura: capa de entrada (1620) → capa oculta 1 (512) → capa oculta 2 (256) → capa de salida (4 clases).

Ruta B: Ventanas temporales → LSTM

- Segmentación en ventanas de $75 \text{ frames} \times 81 \text{ ángulos}$, con desplazamiento de 15 elementos (hasta 45 secuencias por trial).
- Cada ventana produce una matriz 2D de dimensión 75×81 (tiempo $\times$ ángulos).
- Arquitectura: capa de entrada (75×81) → LSTM (128 unidades) → LSTM (64 unidades) → capa de salida (4 clases).

4. Resultados

Modelo	Top-1 (nuestro)	Top-1 (artículo)	Top-2 (nuestro)	Top-2 (artículo)
MLP	40.9%	58.7%	75.0%	80.4%
LSTM	61.4%	67.4%	81.8%	86.9%

- **El LSTM supera al MLP**, tal como predice el artículo. La diferencia frente a las métricas reportadas es ligeramente preocupante y probablemente se debe a inconsistencias en la extracción de características.
- **La Forma III es la más difícil** de clasificar, tanto para nuestros modelos como para el artículo original: se asocia a un déficit de percepción del paciente que no es evidente en los datos de movimiento.
- **Ambos modelos muestran overfitting marcado:** entrenan hasta el 100% de precisión en el conjunto de entrenamiento, sin regularización fuerte aplicada.

5. Conclusiones y Próximos Pasos

Conclusiones

- El pipeline reconstruido desde el dato crudo reproduce la tendencia cualitativa del artículo: LSTM > MLP, y la Forma III es estructuralmente la más difícil de clasificar.
- Queda una brecha cuantitativa frente al artículo original de aproximadamente 10 a 17 puntos porcentuales.
- Candidatos identificados para explicar la brecha: verificación de los 27 ángulos calculados, exceso de trials tras la segmentación de pasos (+85 respecto al artículo), y overfitting sin controlar.

Próximos pasos

- Verificar los tripletes de ángulos contra la Tabla 5 del artículo original.
- Ajustar el criterio de segmentación de pasos para reducir el exceso de trials.
- Agregar regularización a los modelos (early stopping / dropout).

6. Referencias

- Ferrari, A. et al. (2019). Gait-Based Diplegia Classification Using LSTM Networks. Journal of Healthcare Engineering. <https://pubmed.ncbi.nlm.nih.gov/30800255/>
- Repositorio del proyecto: <https://github.com/Bosnape/diplegia-gait>
- Datos crudos: <https://github.com/lucabergamini/gait-analysis-dataset>